Ejercicio Clase 5

1. En el container de Nifi, crear un .sh que permita descargar el archivo yellow_tripdata_2021-01.parquet desde

wget -O /home/fpineyro/test/yellow_tripdata_2021-01.parquet https://data-engineer-edvai-public.s3.amazonaws.com/yellow_tripdata_2021-01.parquet y lo guarde en /home/nifi/ingest. Ejecutarlo.

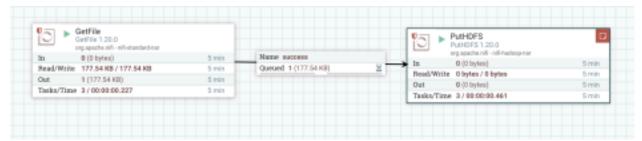
Script con 'curl' en lugar de wget:

nifi@421a768bbd3f:~\$ cat landing_parquet.sh

curl -L -o /home/nifi/ingest/yellow_tripdata_2021-01.parquet https://data-engineer-edvai-public.s3.amazonaws.com/yellow_tripdata_2021-01.parquet

```
nifi@421a768bbd3f:~$ sh landing parquet.sh
 % Total
            % Received % Xferd Average Speed
                                                Time
                                                        Time
                                                                 Time Current
                                Dload Upload
                                                Total
                                                        Spent
                                                                Left
                                                                      Speed
100 20.6M 100 20.6M
                             0 5828k
                                           0 0:00:03
                                                       0:00:03 --:-- 5827k
nifi@421a768bbd3f:~$ cd ingest
nifi@421a768bbd3f:~/ingest$ ls -rtl
total 21180
-rw-r--r-- 1 nifi nifi 21686067 Oct 7 09:28 yellow_tripdata_2021-01.parquet
```

- 2. Por medio de la interfaz gráfica de Nifi, crear un job que tenga dos procesos.
 - a) GetFile para obtener el archivo del punto 1 (/home/nifi/ingest)
 - b) putHDFS para ingestarlo a HDFS (directorio nifi)



Get file:

Edit Processor | GetFile 2.6.0

Settings Scheduling Properties

Required field

Property		Value
Input Directory	0	/home/nifi/ingest
File Filter	0	yellow_tripdata_2021-01.parquet

PutHDFS:

Edit Processor | PutHDFS 2.3.0

Settings Scheduling Properties

Required field

Property		Value	
Hadoop Configuration Resources	0	/home/nifi/hdfs/core-site.xml, /home	
Kerberos User Service	0	No value set	ŧ
Additional Classpath Resources	0	No value set	
Directory	0	/nifi/	
Conflict Resolution Strategy	0	replace	



Listando el directorio /nifi en HDFS se encuentra el archivo parquet que se descargó en nifi.

```
hadoop@5f1a3da9dadf:/home$ hdfs dfs -ls /nifi
Found 2 items
-rw-r--r-- 1 nifi supergroup 6706 2025-10-07 07:22 /nifi/starwars.avro
-rw-r--r-- 1 nifi supergroup 21686067 2025-10-07 07:37 /nifi/yellow_tripdata_2021-01.parquet
```

3. Con el archivo ya ingestado en HDFS/nifi, escribir las consultas y agregar captura de pantalla del resultado. Para los ejercicios puedes usar SQL mediante la creación de una vista llamada yellow_tripdata.

También debes chequear el diccionario de datos por cualquier duda que tengas respecto a las columnas del archivo

https://www.nyc.gov/assets/tlc/downloads/pdf/data_dictionary_trip_records_yellow.pdf

- 3.1) Mostrar los resultados siguientes
 - a. Vendorld Integer
 - b. Tpep_pickup_datetime date
 - c. Total amount double
 - d. Donde el total (total_amount sea menor a 10 dólares)

```
-----
|VendorID|tpep_pickup_datetime|total_amount|
       11
                   2020-12-311
                                      4.31
       21
                   2020-12-31|
                                      8.31
       21
                   2020-12-311
                                     9.961
       21
                   2020-12-311
                                      9.31
       21
                   2020-12-31|
                                      5.81
       11
                   2020-12-311
                                      0.01
       11
                   2020-12-311
                                      9.31
       21
                   2020-12-311
                                      9.81
       21
                   2020-12-311
                                      8.81
       21
                   2020-12-311
                                     9.961
```

	ssion avai - spark.re show(5)				low_tr	ipdata_20	21-01.	parquet")
+	-+		+					
	+							
-+	-+	+		+			+	
+		+						
Vendor]	D tpep_pi	ckup_dat	etime	tpep_dr	opoff_	datetime	passen	ger_count

Creo un dataframe con la sentencia: >>> df_res1 = spark.sql("select cast(VendorID as integer), cast(tpep_pickup_datetime as date), total_amount from yellow_tripdata where total_amount < 10")

*El campo total amount no hace falta castearlo, ya era tipo double.

```
>>> df res1.show(10)
|VendorID|tpep_pickup_datetime|total_amount|
                  2020-12-31
        2
                  2020-12-31
                                      8.3
                   2020-12-31
                                      9.96
                                      9.3
        2
                   2020-12-31
        2
                   2020-12-31
                                       5.8
        1|
                   2020-12-31
                                       0.0
        1
                                       9.3
                   2020-12-31
        2
                   2020-12-31
                                       9.8
        2
                   2020-12-31
                                       8.8
        2
                   2020-12-31
                                      9.96
only showing top 10 rows
```

3.2)Mostrar los 10 días que más se recaudó dinero (tpep_pickup_datetime, total amount)

La forma rápida es: >>> df_3 = spark.sql("select cast(tpep_pickup_datetime as date), sum(total_amount) from yellow_tripdata group by cast(tpep_pickup_datetime as date) order by sum(total_amount) desc LIMIT 10")

Otra forma es crear un dataframe con las columnas tpep_pickup_datetime casteado a date (sino el group by no sale como en la imagen de arriba por los diferentes horarios en el mismo día) y total_amount que ya es tipo double:

>>> df_2 = spark.sql("select cast(tpep_pickup_datetime as date), total_amount from yell ow_tripdata")

Creo una nueva vista del datagrama df_2: >>> df_2.createOrReplaceTempView("yellow_tripdata_2")

Creo datagrama df_3 con el resultado: >>> df_3 = spark.sql("select tpep_pickup_datetime, sum(total_amount) from yellow_tripdata_2 group by tpep_pickup_datetime order by sum(total_amount) desc LIMIT 10")

3.3) Mostrar los 10 viajes que menos dinero recaudó en viajes mayores a 10 millas (trip_distance, total_amount)

Tomo la vista creada en el primer punto yellow_tripdata. Los campos trip_distance y total_amount son de tipo "double". Consulto y guardo en dataframe df_4:

>>> df_4 = spark.sql("select trip_distance, total_amount as total from yellow_tripdata where trip_distance > 10 order by total_amount asc limit 10")

3.4) Mostrar los viajes de más de dos pasajeros que hayan pagado con tarjeta de crédito (mostrar solo las columnas trip_distance y tpep_pickup_datetime)

++	+
trip_distance	tpep_pickup_datetime
++	+
1 2.71	2020-12-31
1.21	2020-12-31
1.16	2020-12-31
0.641	2020-12-31
3.451	2020-12-31
0.521	2020-12-31
1.05	2020-12-31
5.851	2020-12-31
1 3.71	2020-12-31
1 4.01	2020-12-31
+	+

>>> df_5 = spark.sql("select trip_distance, cast(tpep_pickup_datetime as date) from yellow_tripdata where passenger_count > 2 and payment_type = 1 ")

passenger_count > 2 -> Más de 2 pasajeros payment_type = 1 -> pago en tarjeta de crédito

```
df_5.show(10)
trip_distance|tpep_pickup_datetime
          6.11
                          2020-12-31
           1.7
                          2020-12-31
          3.15
                          2020-12-31
         10.74
                          2020-12-31
          2.01
                          2020-12-31
          2.85
                          2020-12-31
          1.68
                          2020-12-31
          0.77
                          2020-12-31
           0.4
                          2020-12-31
         16.54
                          2020-12-31
only showing top 10 rows
```

3.5) Mostrar los 7 viajes con mayor propina en distancias mayores a 10 millas (mostrar campos tpep_pickup_datetime, trip_distance, passenger_count, tip_amount)

```
|trip_distance|tpep_pickup_datetime|passenger_count|tip_amount|
                          2021-01-201
                                                          1140.441
        427.71
                                                    11
        267.71
                          2021-01-03|
                                                    11
                                                            369.41
        326.11
                                                    Ø1
                                                           192.611
                          2021-01-12|
         260.51
                          2021-01-191
                                                    11
                                                           149.031
         11.11
                          2021-01-31|
                                                    Ø I
                                                            100.01
        14.861
                          2021-01-01|
                                                    21
                                                             99.01
         13.01
                          2021-01-18|
                                                    Ø1
                                                             90.01
```

>>> df_6 = spark.sql("select trip_distance,cast(tpep_pickup_datetime as date),passenger_count, tip_amount from yellow_tripdata where trip_distance > 10 order by tip_amount desc limit 7")

```
>>> df_6 = spark.sql("select trip_distance,cast(tpep_pickup_datetime as date)
,passenger_count, tip_amount from yellow_tripdata where trip_distance > 10 or
der by tip amount desc limit 7")
>>> df_6.show(7)
|trip_distance|tpep_pickup_datetime|passenger_count|tip_amount|
         427.7
                         2021-01-20
                                                1.0
                                                       1140.44
         267.7
                         2021-01-03
                                                1.0
                                                         369.4
         326.1
                         2021-01-12
                                                0.0
                                                        192.61
         260.5
                         2021-01-19
                                                1.0
                                                        149.03
         11.1
                         2021-01-31
                                                0.0
                                                         100.0
         14.86
                         2021-01-01
                                                2.0
                                                          99.0
          13.0
                         2021-01-18
                                                0.0
                                                          90.0
```

3.6) Mostrar para cada uno de los valores de RateCodeID, el monto total y el monto promedio. Excluir los viajes en donde RateCodeID es 'Group Ride'

Para que los nombres de columnas coincidan, voy a crear un dataframe.

```
>>> df_8 = spark.sql("select RateCodeID, total_amount as Total_amount from yellow_tripdata where RateCodeID != 6")
```

Y ahora creo una vista tomando como base df_8. >>> df_8.createOrReplaceTempView("yellow2")

Y finalmente creo y muestro el dataframe nuevo con la suma y promedio.

>>> df_9 = spark.sql("select RateCodeID, sum(Total_amount), avg(Total_amount) from yellow2 group by RateCodeID")

```
>>> df_9 = spark.sql("select RateCodeID, sum(Total_amount), avg(Total_amount) from yellow2 group by RateCodeID")
>>> df_9.show()
+-----+
|RateCodeID| sum(Total_amount)| avg(Total_amount)|
+-----+
| 1.0|1.9496468430212937E7|15.606626116946773|
| 4.0| 90039.93000000082| 74.90842762063296|
| 3.0| 67363.26000000043| 78.69539719626219|
| 2.0| 973635.4700000732| 65.52937609369182|
| 99.0| 1748.0699999999997| 48.55749999999999|
| 5.0| 255075.089999999086|48.939963545662096|
+------+
```